

Dossier de recherche académique

L'intégration de l'intelligence artificielle dans la gestion des listes d'attente

Approches probabilistes, statistiques et algorithmiques

Exposé / Mémoire de recherche

Niveau : universitaire / académique

Auteur :

Encadrant :

Année universitaire : 2025-2026

Résumé général

La gestion des listes d'attente constitue un problème central dans de nombreux secteurs : hôpitaux, banques, administrations publiques, centres d'appels, plateformes numériques, transports, logistique, restauration, éducation ou encore services de rendez-vous. Dans tous ces systèmes, une tension apparaît entre une demande variable et des ressources limitées. Cette tension se traduit par des files d'attente, des retards, une insatisfaction des usagers et parfois une perte économique importante.

La théorie classique des files d'attente a fourni, depuis les travaux d'Erlang au début du XXe siècle, un cadre mathématique puissant pour comprendre les phénomènes d'attente. Les modèles comme M/M/1, M/M/c ou M/G/1 permettent de calculer des indicateurs essentiels : longueur moyenne de la file, temps moyen d'attente, taux d'occupation des serveurs, probabilité de saturation ou probabilité qu'un client attende.

Cependant, les systèmes contemporains sont de plus en plus dynamiques : les flux ne sont pas stationnaires, les comportements humains sont difficiles à prévoir, les annulations et absences aux rendez-vous modifient la demande réelle, et les priorités de service peuvent dépendre de critères médicaux, sociaux ou économiques. Dans ce contexte, l'intelligence artificielle apporte des outils complémentaires : apprentissage supervisé, modèles bayésiens, deep learning et apprentissage par renforcement.

Thèse principale : *l'intégration de l'intelligence artificielle — notamment les modèles probabilistes bayésiens, le machine learning supervisé et l'apprentissage par renforcement — transforme la gestion des listes d'attente en dépassant certaines limites des modèles classiques, afin de prédire plus précisément la demande, d'allouer les ressources de manière optimale et de réduire les temps d'attente dans des environnements incertains.*

Plan général du dossier

Partie	Contenu	Pages
Introduction	Contexte, problématique, hypothèses, objectifs et méthodologie	4-6
Partie I	Fondements théoriques : files d'attente, probabilités et indicateurs	7-11
Partie II	Limites des modèles classiques face aux systèmes réels	12-14
Partie III	Intelligence artificielle : modèles, algorithmes et architecture	15-23
Partie IV	Applications sectorielles : santé, hôpitaux intelligents, services, transport	24-30
Partie V	Défis, limites, gouvernance et perspectives futures	31-35
Conclusion	Synthèse, recommandations et ouverture	36-37
Bibliographie	Références scientifiques principales	38-39
Annexe	Formules essentielles et plan oral de soutenance	40

Le dossier suit une progression logique : il part des modèles classiques de la recherche opérationnelle, analyse leurs limites, puis montre comment l'IA peut être utilisée comme instrument prédictif et décisionnel. L'objectif n'est pas d'opposer systématiquement théorie des files d'attente et intelligence artificielle, mais de montrer leur complémentarité.

Introduction : contexte général

Les listes d'attente sont un phénomène universel. Elles apparaissent dès que la demande adressée à un système dépasse temporairement sa capacité de traitement. Dans une banque, les clients attendent devant les guichets ; dans un hôpital, les patients attendent aux urgences ; dans un centre d'appels, les appelants patientent avant d'être pris en charge ; dans un aéroport, les avions attendent l'autorisation d'atterrir ou de décoller.

L'attente n'est pas seulement un problème mathématique. Elle possède aussi une dimension économique, psychologique et sociale. Un temps d'attente élevé peut réduire la satisfaction, provoquer l'abandon d'un service, augmenter le stress des employés et dégrader la qualité perçue. Dans le domaine médical, l'attente peut même avoir des conséquences critiques sur la santé des patients.

Historiquement, la théorie des files d'attente a permis de formaliser ce type de situation grâce aux probabilités. Elle repose sur la modélisation des arrivées, des temps de service, du nombre de serveurs et de la règle de priorité. Ces modèles ont été largement utilisés dans les télécommunications, les transports, l'industrie et les services.

Toutefois, les organisations modernes disposent aujourd'hui de grandes quantités de données : historiques de rendez-vous, temps d'arrivée, durées de service, annulations, taux d'absence, réclamations, capteurs numériques, logs informatiques et données de mobilité. L'intelligence artificielle permet d'exploiter ces données pour améliorer la prédiction et la décision.

Problématique et hypothèses

Problématique

La question centrale de cette recherche est la suivante :

Comment l'intelligence artificielle peut-elle améliorer la gestion des listes d'attente par rapport aux modèles classiques de la théorie des files d'attente ?

Cette problématique implique plusieurs sous-questions : comment prédire les temps d'attente avec précision ? Comment anticiper les pics de demande ? Comment allouer dynamiquement les ressources ? Comment concilier efficacité, équité et transparence ? Comment éviter qu'un algorithme ne produise des décisions injustes ou incompréhensibles ?

Hypothèses de recherche

- **H1** : les modèles classiques sont efficaces lorsque les hypothèses de stationnarité et de distributions simples sont respectées, mais ils deviennent moins performants dans les environnements fortement variables.
- **H2** : les modèles de machine learning supervisé peuvent améliorer la prédiction des temps d'attente en exploitant des données historiques détaillées.
- **H3** : l'apprentissage par renforcement permet d'optimiser dynamiquement l'allocation des ressources dans les systèmes où les décisions doivent être répétées.
- **H4** : les meilleures performances sont obtenues par des approches hybrides combinant modèles de files d'attente, IA prédictive et règles métier explicites.

Méthodologie de recherche

Ce dossier adopte une méthodologie documentaire et analytique. Il s'appuie sur les travaux fondamentaux de la théorie des files d'attente, les recherches contemporaines en apprentissage automatique, ainsi que les applications empiriques dans la santé, les services clients, les transports et la gestion des rendez-vous.

Démarche suivie

1. **Analyse théorique** : présentation des concepts fondamentaux : processus de Poisson, loi exponentielle, notation de Kendall, formule de Little, taux d'utilisation et modèles multi-serveurs.
2. **Analyse critique** : identification des limites des modèles classiques : hypothèses trop restrictives, non-stationnarité, comportements humains et données manquantes.
3. **Analyse algorithmique** : étude des méthodes d'IA utiles : régression, forêts aléatoires, gradient boosting, réseaux de neurones, modèles bayésiens et apprentissage par renforcement.
4. **Analyse sectorielle** : examen de plusieurs domaines d'application : santé, hôpitaux intelligents, centres d'appels, transports et administrations.

La recherche privilégie une approche équilibrée. L'IA n'est pas présentée comme une solution magique, mais comme un outil puissant lorsqu'elle est correctement alimentée par des données fiables, encadrée par des règles éthiques et intégrée à une organisation humaine.

Partie I — Fondements théoriques

1.1 Définition et origine de la théorie des files d'attente

La théorie des files d'attente est une branche des probabilités appliquées et de la recherche opérationnelle. Elle étudie les systèmes dans lesquels des entités, appelées clients, demandes ou tâches, attendent pour recevoir un service. Le mot « client » doit être compris au sens large : il peut désigner une personne, un appel téléphonique, un patient, un véhicule, un programme informatique ou un dossier administratif.

Les origines de cette théorie sont liées aux travaux de l'ingénieur danois Agner Krarup Erlang, qui étudia au début du XXe siècle la congestion des réseaux téléphoniques de Copenhague. Son objectif était de dimensionner correctement les lignes téléphoniques afin de réduire la probabilité qu'un appel ne puisse pas être traité. Ces travaux ont donné naissance à une modélisation mathématique de l'attente.

Depuis, la théorie des files d'attente s'est développée dans de nombreux domaines : télécommunications, informatique, transport aérien, systèmes industriels, supermarchés, hôpitaux, plateformes numériques et services publics. Elle permet de répondre à une question fondamentale : combien de ressources faut-il mobiliser pour maintenir un niveau de service acceptable sans gaspiller les capacités disponibles ?

1.2 Structure d'un système de file d'attente

Un système de file d'attente comprend généralement quatre composantes principales : le processus d'arrivée, le mécanisme de service, la discipline de file et la capacité du système. Le processus d'arrivée décrit la manière dont les clients entrent dans le système. Le mécanisme de service décrit la durée nécessaire pour traiter chaque client. La discipline de file détermine l'ordre de passage. La capacité précise le nombre maximal de clients pouvant être présents dans le système.

Composante	Description	Exemple
Arrivées	Flux de clients entrant dans le système	Patients arrivant aux urgences
Service	Temps nécessaire pour traiter une demande	Durée d'une consultation
Serveurs	Ressources disponibles pour servir	Médecins, guichets, agents
Discipline	Règle d'ordre de passage	FCFS, priorité, triage

Les disciplines les plus connues sont : premier arrivé, premier servi ; dernier arrivé, premier servi ; priorité fixe ; priorité dynamique ; ou service avec rendez-vous. Dans certains domaines, comme la santé, une discipline purement chronologique serait injuste : un patient critique doit passer avant un patient dont l'état est stable.

1.3 Modèles probabilistes fondamentaux

Les files d'attente classiques reposent sur des modèles probabilistes. Le processus de Poisson est souvent utilisé pour représenter les arrivées aléatoires. Si le taux moyen d'arrivée est noté λ , alors le nombre d'arrivées pendant une période donnée suit une loi de Poisson lorsque les arrivées sont indépendantes et réparties de manière homogène dans le temps.

Les temps de service sont fréquemment modélisés par une loi exponentielle de paramètre μ . Cette hypothèse simplifie fortement les calculs, car la loi exponentielle possède une propriété dite « sans mémoire ». Cela signifie que le temps restant ne dépend pas du temps déjà écoulé.

Le modèle M/M/1

Le modèle M/M/1 désigne une file avec arrivées markoviennes, temps de service exponentiels et un seul serveur. Son taux d'utilisation est :

$$\rho = \lambda / \mu$$

Pour que le système soit stable, il faut que $\rho < 1$. Lorsque ρ se rapproche de 1, le serveur est presque toujours occupé et le temps d'attente augmente fortement. Ce phénomène est essentiel : un système utilisé à 95 % peut sembler efficace, mais il devient très sensible au moindre pic de demande.

1.4 Notation de Kendall et formule de Little

La notation de Kendall permet de décrire de manière compacte un système de file d'attente. Sa forme générale est :

$$A / S / c / K / N / D$$

- **A** : loi des arrivées, par exemple M pour Markovien ou Poisson.
- **S** : loi du service, par exemple M pour exponentielle, G pour générale.
- **c** : nombre de serveurs.
- **K** : capacité maximale du système.
- **N** : taille de la population source.
- **D** : discipline de service.

La formule de Little

La formule de Little est l'un des résultats les plus importants de la théorie des files. Elle relie le nombre moyen de clients dans le système, le taux d'arrivée et le temps moyen passé dans le système :

$$L = \lambda W$$

Ici, L représente le nombre moyen de clients dans le système, λ le taux moyen d'arrivée et W le temps moyen de séjour. Cette formule est très générale : elle s'applique à de nombreux systèmes, même lorsque les distributions exactes ne sont pas simples, à condition que le système soit stable.

1.5 Indicateurs de performance

La gestion des listes d'attente ne se limite pas à calculer un temps moyen. Plusieurs indicateurs doivent être suivis afin d'évaluer correctement la qualité d'un système.

Indicateur	Signification	Intérêt managérial
Temps moyen d'attente	Durée moyenne avant le début du service	Mesurer l'expérience usager
Longueur moyenne de file	Nombre moyen de personnes en attente	Dimensionner l'espace et les ressources
Taux d'occupation	Part du temps pendant laquelle les serveurs sont occupés	Évaluer l'utilisation des ressources
Probabilité d'abandon	Probabilité qu'un usager quitte avant d'être servi	Réduire la perte de clients ou de patients
Niveau de service	Pourcentage servi dans un délai cible	Garantir un standard de qualité

Le bon système n'est pas nécessairement celui qui élimine toute attente, car cela exigerait parfois trop de ressources. L'objectif est d'atteindre un compromis entre coût opérationnel, rapidité, satisfaction et équité.

Partie II — Limites des modèles classiques

2.1 Des hypothèses parfois irréalistes

Les modèles classiques sont puissants, mais ils reposent souvent sur des hypothèses simplificatrices : arrivées suivant un processus de Poisson homogène, temps de service exponentiels, indépendance entre les clients, stabilité du taux d'arrivée et comportement rationnel des usagers. Dans la réalité, ces conditions sont rarement parfaitement vérifiées.

Par exemple, les arrivées aux urgences ne sont pas constantes pendant la journée. Elles peuvent augmenter le soir, pendant les week-ends ou lors d'événements exceptionnels. Dans un centre d'appels, les appels peuvent exploser après une panne, une campagne publicitaire ou une annonce administrative. Dans un restaurant, la demande dépend de l'heure, de la météo, des vacances et des habitudes locales.

De plus, les durées de service sont souvent très hétérogènes. Deux patients ayant le même motif apparent peuvent nécessiter des durées de prise en charge très différentes. Deux dossiers administratifs peuvent avoir des niveaux de complexité opposés. Une distribution exponentielle unique peut donc être trop pauvre pour représenter cette diversité.

2.2 Non-stationnarité et saisonnalité

La non-stationnarité signifie que les paramètres du système changent dans le temps. Dans beaucoup de services, le taux d'arrivée λ n'est pas fixe : il varie selon l'heure, le jour de la semaine, le mois, la météo, les vacances, les événements sociaux ou les décisions institutionnelles.

Cette situation rend les calculs stationnaires moins adaptés. Un modèle qui suppose un régime stable peut produire une moyenne correcte sur une journée entière, mais être incapable d'anticiper les pics à 10h, 14h ou 18h. Or c'est précisément pendant ces pics que les files deviennent problématiques.

Exemples de flux non stationnaires

- Urgences hospitalières : pics en soirée, week-end ou période épidémique.
- Centres d'appels : pics après envoi d'un SMS, d'une facture ou d'un communiqué.
- Administrations : pics avant une date limite officielle.
- Transports : pics aux heures de pointe et en période de vacances.
- Plateformes numériques : pics après une promotion ou une panne technique.

L'intelligence artificielle est particulièrement utile dans ce contexte, car elle peut apprendre des cycles temporels et intégrer des variables externes pour prévoir la demande.

2.3 Modèles interprétables ou modèles prédictifs ?

Un débat important oppose parfois les modèles classiques de files d'attente et les modèles de machine learning. Les premiers sont généralement plus interprétables : ils reposent sur des paramètres simples comme λ , μ et c . On comprend facilement pourquoi une hausse du taux d'arrivée augmente l'attente ou pourquoi un serveur supplémentaire réduit la congestion.

Les modèles de machine learning, eux, sont souvent plus performants lorsque les données sont riches et complexes. Ils peuvent intégrer de nombreuses variables : heure d'arrivée, jour, type de service, profil du client, nombre de serveurs disponibles, météo, historique des annulations ou taux d'absence. Cependant, ils peuvent être perçus comme des « boîtes noires ».

Enjeu central : il ne faut pas choisir automatiquement entre théorie des files d'attente et IA. Dans les systèmes modernes, l'approche la plus robuste est souvent hybride : les modèles probabilistes donnent la structure, tandis que l'IA améliore la prédiction et l'adaptation dynamique.

Cette complémentarité est essentielle pour un usage responsable : un système de décision doit être efficace, mais aussi compréhensible, contrôlable et acceptable par les utilisateurs.

3.1 Fondements mathématiques de l'IA probabiliste

L'intelligence artificielle moderne s'appuie sur plusieurs domaines mathématiques : l'algèbre linéaire pour représenter les données sous forme de vecteurs et de matrices, l'optimisation pour ajuster les modèles, les probabilités pour raisonner sous incertitude, et la statistique pour estimer des relations à partir d'observations.

Dans la gestion des listes d'attente, l'incertitude est omniprésente. On ne sait pas exactement combien de personnes arriveront dans l'heure suivante, combien de temps durera chaque service, combien d'utilisateurs annuleront leur rendez-vous ou combien abandonneront la file. L'IA permet de produire des estimations probabilistes à partir des données passées.

La logique probabiliste est donc au cœur de l'IA appliquée aux files d'attente. Un modèle prédictif ne dit pas seulement : « le temps d'attente sera de 25 minutes ». Il peut aussi fournir une incertitude : « il y a 80 % de chances que le temps d'attente soit compris entre 20 et 35 minutes ». Cette information est précieuse pour organiser les ressources.

3.2 Inférence bayésienne

L'inférence bayésienne est une méthode statistique permettant de mettre à jour une croyance initiale lorsqu'une nouvelle information devient disponible. Elle repose sur le théorème de Bayes :

$$P(A|B) = [P(B|A) \times P(A)] / P(B)$$

Dans la gestion d'une file, A peut représenter l'hypothèse « forte affluence aujourd'hui » et B une observation telle qu'un nombre élevé d'arrivées pendant les trente premières minutes. Le modèle met alors à jour la probabilité d'une journée chargée.

Utilité pour les listes d'attente

- Estimer la probabilité d'un pic de demande à partir des premières observations.
- Actualiser les prévisions en temps réel.
- Intégrer une connaissance experte, par exemple les jours traditionnellement chargés.
- Produire des intervalles de crédibilité plutôt qu'une seule valeur moyenne.

Les modèles bayésiens sont particulièrement intéressants lorsque les données sont limitées ou lorsque l'on souhaite combiner données historiques et expertise humaine. Ils offrent une approche transparente de l'incertitude.

3.3 IA prédictive et données nécessaires

L'IA prédictive consiste à utiliser des données historiques pour anticiper des événements futurs. Dans le cas des listes d'attente, elle permet de prévoir le nombre d'arrivées, la durée probable du service, le risque d'annulation, le risque de no-show, le temps d'attente ou la probabilité d'abandon.

Variables fréquemment utilisées

Catégorie	Exemples de variables
Temps	Heure, jour, mois, vacances, saison, date limite
File	Longueur actuelle, temps moyen récent, nombre de serveurs actifs
Client / patient	Type de demande, priorité, historique de rendez-vous, risque d'absence
Contexte	Météo, événement local, panne, campagne d'information

Une bonne prédiction dépend fortement de la qualité des données. Des données incomplètes, mal horodatées ou biaisées peuvent conduire à des décisions erronées. Avant l'algorithme, il faut donc un travail sérieux de collecte, nettoyage, anonymisation et validation.

3.4 Machine learning supervisé

Le machine learning supervisé consiste à entraîner un modèle à partir d'exemples connus. Dans notre cas, les données historiques contiennent des situations passées avec leurs caractéristiques et le temps d'attente réellement observé. Le modèle apprend ensuite une fonction capable de prédire le temps d'attente pour de nouvelles situations.

Algorithmes courants

- **Régression linéaire et ridge** : simples, interprétables, utiles comme base.
- **Random Forest** : robuste, capable de traiter des relations non linéaires.
- **Gradient Boosting** : souvent très performant pour les données tabulaires.
- **Extra Trees** : variante d'arbres très aléatoires, efficace et stable.
- **Réseaux de neurones** : adaptés aux grands volumes et aux données complexes.

Les variables les plus importantes sont souvent la longueur actuelle de la file, l'heure d'arrivée, le nombre de serveurs disponibles et le type de demande. Ces résultats rejoignent l'intuition de la théorie des files : plus la file est longue et plus les ressources sont limitées, plus l'attente augmente.

3.5 Évaluation des modèles prédictifs

Un modèle d’IA doit être évalué rigoureusement avant d’être utilisé. Il ne suffit pas qu’il semble fonctionner sur les données d’entraînement. Il faut tester sa capacité à généraliser à de nouvelles situations.

Mesures d’évaluation

Mesure	Définition	Interprétation
MAE	Erreur absolue moyenne	Erreur moyenne en minutes
RMSE	Racine de l’erreur quadratique moyenne	Pénalise fortement les grosses erreurs
MAPE	Erreur relative moyenne	Exprime l’erreur en pourcentage
R ²	Part de variance expliquée	Mesure globale d’ajustement

Dans une application réelle, il faut également mesurer l’impact opérationnel : réduction du temps d’attente, baisse des abandons, satisfaction des usagers, meilleure utilisation des ressources et respect des contraintes d’équité.

3.6 Deep learning et files dynamiques

Le deep learning devient utile lorsque les données sont volumineuses, séquentielles ou complexes. Dans une file d'attente dynamique, l'état actuel dépend fortement de l'évolution passée : arrivées successives, durées de service précédentes, variations horaires et effets de congestion.

Les réseaux de neurones récurrents, les modèles LSTM ou GRU, et plus récemment les architectures de type Transformer, peuvent apprendre des dépendances temporelles. Ils permettent par exemple de prévoir la demande sur les prochaines heures à partir d'une séquence historique.

Exemples d'utilisation

- Préviation du nombre de patients attendus aux urgences heure par heure.
- Prédiction de la charge d'un centre d'appels après une campagne de communication.
- Estimation du temps d'attente en temps réel sur une application mobile.
- Détection précoce d'un risque de saturation.

Le deep learning offre de bonnes performances, mais nécessite beaucoup de données, des compétences techniques et un contrôle strict pour éviter les prédictions instables ou difficilement explicables.

3.7 Apprentissage par renforcement

L'apprentissage par renforcement est une méthode d'IA dans laquelle un agent apprend à prendre des décisions successives en interagissant avec un environnement. À chaque étape, il observe un état, choisit une action et reçoit une récompense. Son objectif est de maximiser la récompense totale à long terme.

Dans une file d'attente, l'état peut être la longueur actuelle de la file, le nombre de serveurs disponibles, le niveau d'urgence des clients et les prévisions d'arrivée. Les actions peuvent être : ouvrir un guichet supplémentaire, affecter un médecin à un service, prioriser certains dossiers ou envoyer des notifications de rendez-vous.

Exemple simplifié

État	Action possible	Récompense
File longue, faible personnel	Ajouter un agent	Réduction de l'attente
File courte, trop de serveurs	Réaffecter une ressource	Réduction du coût
Patient critique	Priorité immédiate	Amélioration médicale

Le Q-learning et les méthodes de deep reinforcement learning sont particulièrement étudiés pour l'allocation dynamique des ressources.

3.8 Approches hybrides

Les approches hybrides combinent les avantages de la théorie des files d'attente et ceux de l'intelligence artificielle. La théorie fournit un cadre explicable, fondé sur des relations mathématiques connues. L'IA ajoute une capacité d'apprentissage à partir de données réelles, souvent plus complexes que les hypothèses classiques.

Architecture type

1. Collecte des données historiques et en temps réel.
2. Prévvision de la demande par machine learning ou modèle bayésien.
3. Simulation de scénarios à l'aide de modèles de files d'attente.
4. Optimisation des décisions par apprentissage par renforcement ou programmation.
5. Contrôle humain et règles éthiques de priorité.

Cette approche est pertinente car elle réduit le risque de dépendre uniquement d'un modèle opaque. Un système hybride peut expliquer une partie de ses décisions par des indicateurs classiques, tout en utilisant l'IA pour mieux anticiper les variations.

L'objectif n'est pas seulement de prédire l'attente, mais de décider quoi faire pour la réduire : ajouter des ressources, réorganiser les rendez-vous, informer les usagers ou prioriser certains cas.

3.9 Pipeline opérationnel d'un système IA

Pour déployer une solution d'IA dans la gestion d'une liste d'attente, il faut suivre un processus structuré. Une simple prédiction isolée n'est pas suffisante : le modèle doit être intégré à l'organisation et mis à jour régulièrement.

Étapes principales

- **Diagnostic** : comprendre le fonctionnement actuel de la file.
- **Données** : collecter, nettoyer, anonymiser et sécuriser les données.
- **Modélisation** : construire des modèles prédictifs et probabilistes.
- **Simulation** : tester différents scénarios sans perturber le service réel.
- **Décision** : recommander des actions opérationnelles.
- **Évaluation** : mesurer les résultats après déploiement.
- **Amélioration continue** : réentraîner les modèles et corriger les biais.

La réussite dépend autant de la technologie que de la conduite du changement. Les agents, médecins, administrateurs ou responsables de service doivent comprendre le rôle de l'outil, ses limites et la manière dont il assiste la décision humaine.

Partie IV — Applications sectorielles

4.1 Secteur de la santé

Le secteur de la santé est l'un des domaines où la gestion des files d'attente est la plus critique. Les patients attendent pour obtenir un rendez-vous, accéder aux urgences, passer un examen, être hospitalisés ou recevoir une intervention. Une mauvaise gestion peut provoquer une perte de chance médicale, une surcharge du personnel et une insatisfaction importante.

L'IA peut améliorer plusieurs aspects : prédiction du flux de patients, estimation de la durée de séjour, détection des risques de saturation, aide au triage et allocation dynamique des médecins, infirmiers ou lits. Les modèles peuvent aussi anticiper les absences aux rendez-vous et proposer une stratégie de rappel.

Effets attendus

- Réduction du temps d'attente aux urgences.
- Meilleure utilisation des lits et des salles d'examen.
- Priorisation plus cohérente des cas critiques.
- Prévision des périodes de surcharge.
- Diminution du stress organisationnel.

Dans ce domaine, l'IA doit impérativement rester un outil d'aide à la décision. La décision clinique finale doit appartenir aux professionnels de santé.

4.2 Hôpitaux intelligents

Les hôpitaux intelligents utilisent des systèmes numériques pour suivre les patients, les ressources, les équipements et les flux en temps réel. L'objectif est de rendre l'organisation plus réactive. Les files d'attente ne sont plus considérées comme de simples files physiques, mais comme des flux complexes reliant accueil, triage, consultation, examens, hospitalisation et sortie.

Les algorithmes de deep reinforcement learning peuvent être utilisés pour planifier les consultations, répartir les patients entre différents services, affecter les salles ou ajuster les horaires. Les réseaux de neurones de graphes sont également pertinents lorsque les parcours patients ressemblent à des réseaux d'activités interdépendantes.

Exemple de décision intelligente

Si le système prévoit une hausse des arrivées dans deux heures, il peut recommander de décaler certains rendez-vous non urgents, d'ouvrir une salle supplémentaire, de mobiliser du personnel ou de prévenir les patients de délais possibles. Cette anticipation réduit les réactions tardives et améliore la fluidité globale.

La difficulté principale réside dans l'intégration des données hospitalières : dossiers patients, disponibilité du personnel, équipements, niveaux d'urgence et contraintes légales.

4.3 Services clients et rendez-vous

Les services clients, banques, assurances, administrations et plateformes de rendez-vous utilisent de plus en plus l'IA pour réduire les délais. Les algorithmes peuvent prévoir le nombre d'appels, organiser les plannings, estimer les temps d'attente et envoyer des notifications automatiques.

Un problème fréquent est le no-show, c'est-à-dire l'absence d'un usager à son rendez-vous. L'IA peut calculer un risque d'absence selon plusieurs facteurs : historique, heure du rendez-vous, délai depuis la prise de rendez-vous, type de service et réaction aux rappels. Cette prédiction permet d'envoyer des rappels personnalisés ou de proposer le créneau à une personne en liste d'attente.

Fonctions utiles

- Notification automatique des personnes en attente.
- Réaffectation rapide des créneaux annulés.
- Prévission du volume d'appels.
- Routage intelligent vers l'agent le plus compétent.
- Affichage d'un temps d'attente estimé en temps réel.

L'amélioration de la satisfaction vient autant de la réduction réelle de l'attente que de la réduction de l'incertitude : un usager accepte mieux d'attendre s'il connaît le délai.

4.4 Transport, logistique et mobilité

Les systèmes de transport sont remplis de files d'attente : avions avant le décollage, camions dans les ports, véhicules aux péages, voyageurs aux contrôles de sécurité, taxis ou VTC en attente de clients. Dans ces contextes, le coût de l'attente peut être très élevé, car il affecte les délais, la consommation d'énergie et la satisfaction.

L'IA permet de prévoir la demande de transport, d'optimiser les horaires, de réguler les flux et de réduire les congestions. Dans les ports et entrepôts, les modèles prédictifs peuvent anticiper l'arrivée des camions et proposer des créneaux dynamiques de chargement. Dans les aéroports, ils peuvent aider à dimensionner les contrôles de sécurité selon les vagues de départ.

Applications possibles

- Gestion dynamique des files aux péages et parkings.
- Optimisation des créneaux de livraison.
- Réduction de l'attente dans les terminaux à conteneurs.
- Prévion de la demande de taxis ou navettes.
- Gestion des flux de passagers dans les gares et aéroports.

4.5 Administrations, éducation et services publics

Les administrations publiques sont souvent confrontées à des files importantes : demandes de passeports, inscriptions, aides sociales, titres de séjour, impôts ou services municipaux. Les délais peuvent être mal vécus, car ils touchent parfois des droits fondamentaux.

L'IA peut contribuer à mieux planifier les rendez-vous, identifier les périodes de forte demande, détecter les dossiers incomplets et orienter les usagers vers le bon canal. Elle peut également aider à prioriser certains cas selon des critères transparents, par exemple urgence sociale, échéance légale ou vulnérabilité.

Dans l'éducation, les listes d'attente apparaissent pour les inscriptions, les formations, les logements universitaires ou l'accès à certains services. Les modèles prédictifs peuvent anticiper les désistements et accélérer l'attribution des places.

Dans le secteur public, l'utilisation de l'IA doit être particulièrement encadrée : explicabilité, non-discrimination, possibilité de recours et respect des données personnelles.

4.6 Synthèse des résultats empiriques

Les études appliquées montrent généralement que l'IA peut améliorer la performance des systèmes d'attente, surtout lorsque la demande est variable et que les données historiques sont disponibles. Les gains observés portent sur la prédiction, la planification et la décision dynamique.

Domaine	Apport de l'IA	Résultat attendu
Santé	Prévision des arrivées, triage, allocation des lits	Réduction de l'attente et meilleure priorisation
Centres d'appels	Prévision du volume, routage intelligent	Baisse des abandons et meilleure qualité de service
Rendez-vous	Prédiction du no-show, rappels personnalisés	Meilleur taux d'occupation des créneaux
Transport	Prévision de congestion, allocation dynamique	Fluidité accrue et réduction des retards

Toutefois, les résultats dépendent fortement du contexte. Un modèle performant dans un hôpital peut ne pas être directement transférable à une administration ou à un centre d'appels. Chaque système possède ses propres contraintes.

4.7 Comparaison : modèles classiques et IA

Critère	Théorie des files d'attente	Intelligence artificielle	Approche hybride
Interprétabilité	Très bonne	Variable selon l'algorithme	Bonne si bien conçue
Données nécessaires	Faibles à modérées	Souvent importantes	Modérées à importantes
Adaptation temps réel	Limitée	Forte	Forte
Gestion de la complexité	Bonne si hypothèses simples	Très bonne avec données riches	Très bonne
Risque	Modèle trop simplifié	Boîte noire, biais, surapprentissage	Complexité de mise en œuvre

Cette comparaison montre que l'IA ne remplace pas mécaniquement la théorie des files d'attente. Elle l'enrichit. Les modèles classiques restent indispensables pour comprendre les mécanismes fondamentaux, tandis que l'IA permet d'exploiter les données réelles pour produire des décisions plus adaptées.

5.1 Qualité des données

Le premier défi de l'IA est la qualité des données. Un modèle entraîné sur des données incomplètes ou erronées produira des prédictions peu fiables. Dans les listes d'attente, plusieurs problèmes apparaissent : horodatages manquants, durée de service mal enregistrée, données non standardisées, doublons, erreurs humaines ou changements d'organisation.

Il faut également distinguer le temps d'attente réel du temps perçu. Un système peut enregistrer l'heure d'arrivée administrative, mais l'utilisateur peut avoir commencé à attendre avant son enregistrement. De même, dans un centre d'appels, le temps d'attente technique ne reflète pas toujours la frustration ressentie.

Bonnes pratiques

- Définir clairement les événements : arrivée, début de service, fin de service.
- Standardiser les formats de données.
- Supprimer ou corriger les anomalies.
- Documenter les changements organisationnels.
- Contrôler régulièrement les performances du modèle.

5.2 Biais, équité et acceptabilité sociale

L'IA peut reproduire ou amplifier des biais présents dans les données. Si certains groupes ont historiquement attendu plus longtemps, un modèle pourrait considérer cette situation comme normale et continuer à les désavantager. L'efficacité ne doit donc pas être le seul critère d'évaluation.

L'équité dans une file d'attente peut avoir plusieurs définitions : égalité stricte du temps d'attente, priorité selon l'urgence, priorité aux personnes vulnérables, ou respect de l'ordre d'arrivée. Ces objectifs peuvent entrer en conflit. Par exemple, prioriser les urgences médicales est équitable, même si cela augmente l'attente de certains patients moins graves.

Principes à respecter

- Définir explicitement les règles de priorité.
- Éviter les variables discriminatoires non justifiées.
- Mesurer l'impact du modèle sur différents groupes.
- Prévoir une intervention humaine possible.
- Informer les usagers lorsque l'IA influence la décision.

5.3 Explicabilité, gouvernance et protection des données

Dans les secteurs sensibles, un algorithme ne peut pas se contenter d'être performant : il doit aussi être explicable. Les responsables doivent comprendre pourquoi une décision est recommandée, surtout lorsqu'elle concerne l'accès à un soin, à un service public ou à une ressource rare.

L'explicabilité peut être améliorée grâce à des modèles simples, des indicateurs de contribution des variables, des règles métier et des outils comme LIME ou SHAP. Il est aussi possible d'utiliser l'IA pour prédire, puis de laisser la décision finale à un module d'optimisation transparent.

Gouvernance recommandée

- Nommer un responsable du système algorithmique.
- Documenter les données, les objectifs et les limites du modèle.
- Mettre en place des audits réguliers.
- Respecter la réglementation sur les données personnelles.
- Prévoir un mécanisme de recours ou de correction.

La confiance dépend de la transparence. Un système incompris risque d'être rejeté, même s'il améliore statistiquement les performances.

5.4 Limites techniques et organisationnelles

Plusieurs limites doivent être prises en compte. D'abord, les modèles d'IA peuvent subir un surapprentissage : ils mémorisent les données passées sans bien généraliser. Ensuite, les comportements des usagers peuvent changer lorsque le système change. Par exemple, si l'application annonce des temps d'attente courts à certaines heures, les usagers peuvent tous venir à ce moment-là, créant une nouvelle congestion.

Les coûts techniques ne sont pas négligeables : infrastructure informatique, maintenance, cybersécurité, formation du personnel, intégration aux logiciels existants et mise à jour des modèles. Une petite organisation peut préférer un modèle simple mais robuste plutôt qu'un système très sophistiqué difficile à maintenir.

Risques principaux

- Dépendance excessive à l'algorithme.
- Modèle obsolète après changement d'organisation.
- Données insuffisantes ou non représentatives.
- Résistance du personnel ou des usagers.
- Difficulté à mesurer le bénéfice réel.

5.5 Perspectives futures et recommandations

Les prochaines années devraient voir se développer des systèmes de gestion des files de plus en plus intelligents, capables de combiner prévision, simulation, optimisation et interaction avec les usagers. L'IA générative pourrait aussi être utilisée pour expliquer les délais, proposer des alternatives et assister les agents dans la prise de décision.

Recommandations opérationnelles

1. Commencer par un diagnostic précis des files existantes.
2. Utiliser d'abord des indicateurs simples et fiables.
3. Construire progressivement des modèles prédictifs.
4. Comparer l'IA aux modèles classiques avant déploiement.
5. Maintenir un contrôle humain pour les décisions sensibles.
6. Mesurer l'équité en plus de la performance moyenne.
7. Mettre à jour régulièrement les modèles.

La meilleure stratégie consiste à avancer par étapes. Une organisation peut commencer par prédire la demande, puis prédire les temps d'attente, puis optimiser les plannings, et enfin introduire des décisions dynamiques en temps réel.

Conclusion générale

La gestion des listes d'attente est un problème ancien, mais toujours actuel. Depuis les travaux d'Erlang, la théorie des files d'attente a fourni un langage mathématique solide pour comprendre les mécanismes d'arrivée, de service, de congestion et de stabilité. Les modèles classiques restent indispensables pour analyser les systèmes et expliquer les relations fondamentales entre demande, capacité et attente.

Cependant, les systèmes contemporains sont marqués par une complexité croissante : flux variables, comportements imprévisibles, données massives, exigences de qualité, contraintes économiques et attentes élevées des usagers. Dans ce contexte, les hypothèses classiques deviennent parfois insuffisantes. L'intelligence artificielle apporte alors une réponse complémentaire.

Les modèles supervisés permettent de prédire les temps d'attente et les absences. Les modèles bayésiens offrent une gestion rigoureuse de l'incertitude. Le deep learning permet d'analyser des séquences temporelles complexes. L'apprentissage par renforcement ouvre la voie à une allocation dynamique des ressources. Ensemble, ces approches peuvent réduire les temps d'attente, améliorer l'utilisation des ressources et renforcer la qualité du service.

Conclusion : ouverture

La thèse défendue dans ce dossier peut être reformulée ainsi : l'IA ne remplace pas la théorie des files d'attente, elle la prolonge. Les probabilités fournissent la structure, tandis que l'apprentissage automatique donne la capacité d'adaptation. Les systèmes les plus efficaces sont donc ceux qui combinent rigueur mathématique, données réelles, expertise humaine et gouvernance responsable.

Pour une soutenance orale, il est important d'insister sur trois idées fortes. Premièrement, l'attente est un phénomène probabiliste : elle ne peut pas être supprimée totalement, seulement maîtrisée. Deuxièmement, l'IA permet de passer d'une gestion réactive à une gestion prédictive et proactive. Troisièmement, toute solution algorithmique doit être évaluée non seulement par sa performance, mais aussi par son équité, sa transparence et son acceptabilité.

Réponse finale à la problématique : l'intelligence artificielle améliore la gestion des listes d'attente lorsqu'elle est utilisée pour prévoir la demande, estimer les délais, simuler les scénarios et recommander des décisions dynamiques, tout en restant encadrée par des modèles explicables et une responsabilité humaine.

L'avenir de la gestion des files d'attente sera donc probablement hybride : probabiliste, statistique, algorithmique et humain.

Bibliographie indicative — Théorie des files

- Erlang, A. K. (1909). *The Theory of Probabilities and Telephone Conversations*. Nyt Tidsskrift for Matematik B.
- Erlang, A. K. (1917). *Solution of some Problems in the Theory of Probabilities of Significance in Automatic Telephone Exchanges*.
- Kendall, D. G. (1953). *Stochastic Processes Occurring in the Theory of Queues and their Analysis by the Method of the Imbedded Markov Chain*. Annals of Mathematical Statistics.
- Little, J. D. C. (1961). *A Proof for the Queuing Formula $L = \lambda W$* . Operations Research.
- Gross, D., Shortle, J. F., Thompson, J. M., & Harris, C. M. (2018). *Fundamentals of Queueing Theory*. Wiley.
- Kleinrock, L. (1975). *Queueing Systems, Volume 1: Theory*. Wiley.
- Wolff, R. W. (1989). *Stochastic Modeling and the Theory of Queues*. Prentice Hall.
- Cooper, R. B. (1981). *Introduction to Queueing Theory*. North Holland.
- Whitt, W. (2002). *Stochastic-Process Limits*. Springer.
- Gans, N., Koole, G., & Mandelbaum, A. (2003). *Telephone Call Centers: Tutorial, Review, and Research Prospects*. Manufacturing & Service Operations Management.
- Green, L. V. (2006). *Queueing Analysis in Healthcare*. Patient Flow: Reducing Delay in Healthcare Delivery.
- Mandelbaum, A., & Zeltyn, S. (2013). *Data-Stories about Call Centers*. Queueing Systems.

Bibliographie indicative — IA, ML et optimisation

- Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. Springer.
- Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning*. Springer.
- Murphy, K. P. (2012). *Machine Learning: A Probabilistic Perspective*. MIT Press.
- Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. MIT Press.
- Sutton, R. S., & Barto, A. G. (2018). *Reinforcement Learning: An Introduction*. MIT Press.
- Puterman, M. L. (1994). *Markov Decision Processes: Discrete Stochastic Dynamic Programming*. Wiley.
- Breiman, L. (2001). *Random Forests*. Machine Learning.
- Friedman, J. H. (2001). *Greedy Function Approximation: A Gradient Boosting Machine*. Annals of Statistics.
- Chen, T., & Guestrin, C. (2016). *XGBoost: A Scalable Tree Boosting System*. Proceedings of KDD.
- Ribeiro, M. T., Singh, S., & Guestrin, C. (2016). “Why Should I Trust You?” *Explaining the Predictions of Any Classifier*. KDD.
- Lundberg, S. M., & Lee, S. I. (2017). *A Unified Approach to Interpreting Model Predictions*. NeurIPS.
- OCDE. (2019). *Principes de l’OCDE sur l’intelligence artificielle*.
- CNIL. *Intelligence artificielle et protection des données personnelles*.

Annexe — Formules et plan oral

Formules essentielles

- $\rho = \lambda / \mu$: taux d'utilisation pour un serveur.
- $L = \lambda W$: formule de Little.
- $P(A|B) = P(B|A) P(A) / P(B)$: théorème de Bayes.
- $M/M/1$: arrivées markoviennes, service exponentiel, un serveur.
- $M/M/c$: arrivées markoviennes, service exponentiel, c serveurs.

Plan conseillé pour la soutenance orale

1. Présenter le problème : pourquoi les listes d'attente sont importantes.
2. Expliquer brièvement la théorie classique des files.
3. Montrer les limites : flux variables, no-show, priorités, complexité.
4. Introduire l'IA : prédiction, bayésien, ML supervisé, deep learning, RL.
5. Donner des exemples : santé, rendez-vous, centres d'appels, transport.
6. Discuter les risques : biais, données, explicabilité, gouvernance.
7. Conclure : l'avenir est dans les modèles hybrides.

Phrase finale possible : « L'intelligence artificielle ne supprime pas l'incertitude des files d'attente ; elle permet de mieux la mesurer, de mieux l'anticiper et de mieux décider face à elle. »